

# Dichiarazione sull'utilizzo di strumenti di Intelligenza Artificiale Generativa

**Studentesse: Valentina Jin, Elisa Marzioli**

**Strumenti di IA Generativa utilizzati:** Claude (Anthropic), ChatGPT (OpenAI)

**Attività coinvolte dall'utilizzo di AI generativa:**

- Organizzazione e gestione del progetto: comprensione tempistiche e milestone principali.
- Sviluppo del codice.
- Debugging: analisi dei logging, brainstorming di possibili cause.
- Individuazione di criticità e suggerimenti di ottimizzazione.
- Supporto all'installazione e primi utilizzi dei tool coinvolti.
- Miglioramento stilistico della relazione: suggerimenti di sintesi, valutazioni critiche su aspetti da migliorare.

**Parti generate o significativamente modificate con supporto di IA:**

- Versioni iniziali di parti del codice PySpark delle query e degli script di supporto, inizialmente generate a partire da specifiche dettagliate da noi fornite. Il codice è stato successivamente manualmente valutato, corretto, integrato nelle sue parti mancanti, testato e validato dalle studentesse, in particolare sugli aspetti più sottili e fondamentali quali la logica delle query, i meccanismi di caching, le misurazioni dei tempi (con particolare attenzione al lazy evaluation di Spark), nonché l'integrazione tra le varie componenti.
- Codice di utilità: script Python per la generazione di tabelle Word e grafici box-plot, script di launch/automatizzazione dell'esecuzione (run.sh, start.sh, esecuzione benchmark); script Python per l'analisi iniziale del dataset raw CSV (numero di valori mancanti o invalidi, inconsistenze, conteggi).
- Versione iniziale del DAG Airflow per la pipeline, successivamente revisionata.
- Revisione formale (grammatica, stile) di alcune sezioni della relazione.

**Contenuti revisionati, modificati o validati dalle studentesse:**

- Tutto il codice generato è stato revisionato, valutato, testato e corretto nel contesto reale del sistema (Docker Compose, HDFS, Spark 3.5.3 su WSL2).
- Tutte le configurazioni sono state riadattate al contesto di deploy scelto sulla base di analisi propria (assegnazione delle risorse quali core e RAM, numero di Worker, etc.).
- La correzione generale della logica della raccolta dei tempi e gestione del caching, relativamente alle quali il codice generato era piuttosto carente e di qualità subottimale.

**Contenuti originali (senza coinvolgimento di IA):**

- Brainstorming iniziale e architettura del sistema.
- Scelta dei framework (NiFi, Redis, Airflow, Grafana) e della separazione delle loro responsabilità sulla base dei requisiti di progetto e delle conoscenze maturate durante il corso.
- Validazione e verifica dei risultati.
- Analisi e discussione dei risultati.
- Tutte le decisioni progettuali, tra cui:
  - Pre-processing: scelta di delegare la fase di preprocessing a Spark anziché a NiFi, per garantire scalabilità; scelta della gestione dei valori null; scelta dell'eventuale partizionamento del dataset;
  - Analisi e confronto dei possibili data store per il serving layer e scelta finale;
  - Definizione degli esperimenti: confronto warm-up vs. cold start, DataFrame vs. RDD, scalabilità al variare del numero di worker; impatto dell'uso dell'operazione `.cache()`.
  - Logica finale di implementazione delle query;
  - Metodologia e configurazione di benchmarking;
  - Individuazione delle metriche di performance di interesse (end-to-end, loading, computation, output) e scelte relative;
- Tutte le conclusioni sono state elaborate direttamente dalle studentesse sulla base degli obiettivi iniziali dello studio e gli esiti degli esperimenti condotti sul sistema.